



Transfer Learning For Brain Tumor Classification

Réalisé par:

Youssef Snoussi
Iliass Bendidia

Encadré par:

Prof. Abd Elhak Mahmoudi



Plan

- I. INTRODUCTION
- II. DESCRIPTION DES DONNEES UTILISEES
- III. TRANSFER LEARNING POUR LA CLASSIFICATION DES TUMEURS
- IV. RÉSULTATS
- V. CONCLUSION



INTRODUCTION

Le développement des méthodes de calcul et surtout des machines ont ouvert un grand port pour les applications de l'intelligence artificielle dans les diverses domaines de la vie humaine.

Ces applications sont davantage très importantes dans le domaine biomédical et surtout dans la santé où le diagnostic précoce joue un rôle majeur dans le traitement.

Le cancer est l'une de ces maladies qui nécessitent un diagnostic précoce car, une fois qu'il est à un stade avancé, le traitement est presque impossible.

L'intelligence artificielle et précisément le "Transfer Learning" peuvent aider à gagner du temps et de la précision dans ce domaine.



DONNÉES UTILISÉES


Les données utilisées dans ce projet sont disponible sur le site “The Cancer Imaging Archive”.

Ces données concernent 110 patients inclus dans le projet “The Cancer Genome Atlas”.

Elles contiennent des images d’IRM des patient atteint du cancer du cerveau, et des masks de chaque scan montrant l’emplacement des tumeurs, sous format TIF.

Ces images sont aussi disponible sur le site “Kaggle” sous le nom “ Brain MRI segmentation ”.

DONNÉES UTILISÉES



2556 échantillons des
patients sans tumeur

1373 échantillons des
patients avec tumeur



Transfer Learning


Le Transfer Learning est une technique de l'apprentissage profond qui s'appuie sur l'utilisation des modèles déjà entraînés sur un grand nombre d'images.

Cette technique consiste à transférer les connaissances acquise par ces modèles vers notre modeles pour obtenir de meilleurs résultats

Parmis les modèles pré-entraînés les plus célèbres on trouve: VGG, Inception, et ResNet.

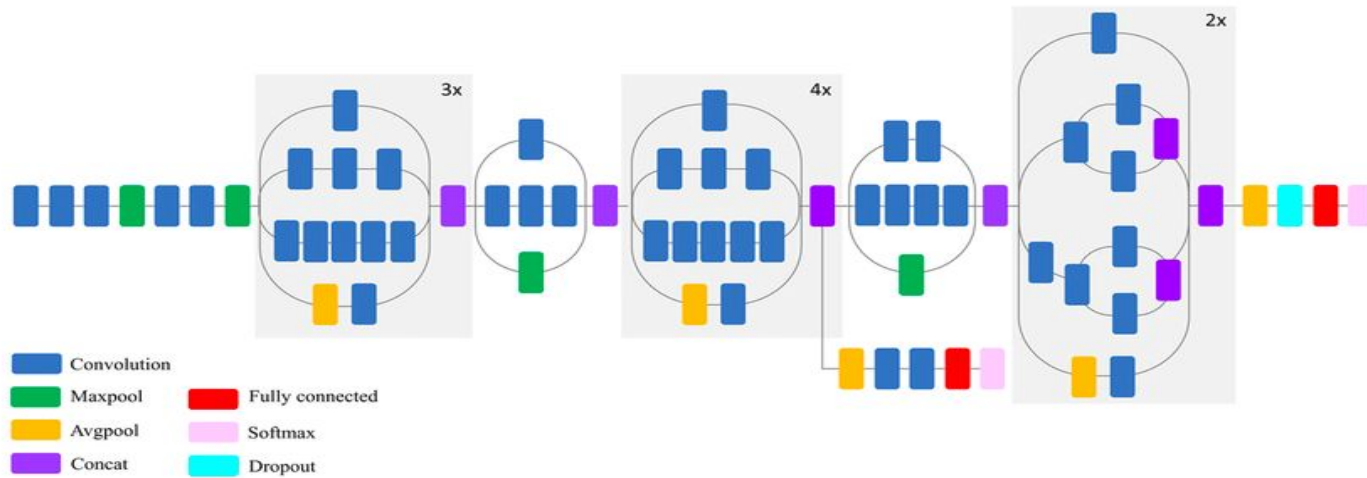
Dans notre projet on utiliser les variations VGG16 et Inception V3 sur la même dataset et avec la même couche d'entraînement pour pouvoir déterminer celui avec les meilleurs résultats.

VGG-16



Architecture de VGG-16


INCEPTION V3




Architecture de INCEPTION V3

Résultats

VGG 16 fixé avec une couche de sortie “sigmoid”




Train and validation loss




Train and validation accuracy

Résultats

VGG 16 Fine Tuning



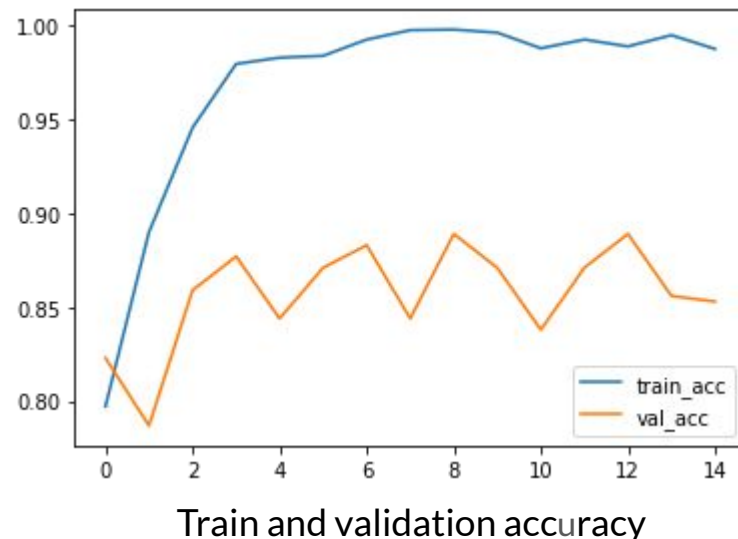
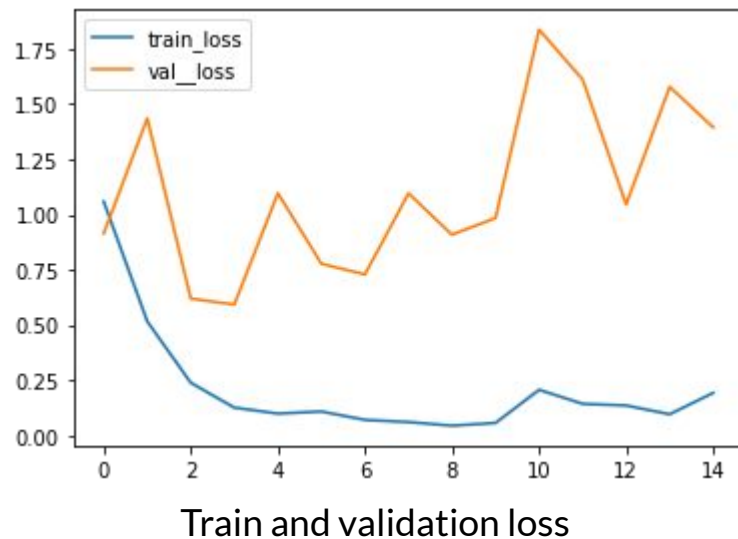
Train and validation loss



Train and validation accuracy


Résultats

Inception V3 fixé avec une couche de sortie “sigmoid”




Résultats

Inception V3 Fine Tuning



Train and validation loss



Train and validation accuracy



Conclusion

Le modèle VGG16 a présenté de meilleurs résultats après le fine tuning avec une précision de 94%

Le modèle Inception V3 a été amélioré après le fine tuning mais pas avec une grande différence puisque la précision était 88% est devenue 89%

L'absence d'équilibre dans notre données est une cause principale de ce problème.